

Milestone 1 - Zrozumienie zbioru danych

1. Kontekst i opis zbioru danych

Środowisko produkcyjne

Analizowany zbiór pochodzi z laboratoryjnego środowiska produkcyjnego **Fischertechnik** (model fabryki modułowej), opisanego w publikacji na platformie Zenodo (<https://zenodo.org/records/8087219>). Jest to cyber-fizyczny system produkcyjny złożony z kilku stacji roboczych połączonych transporterem. Każda stacja realizuje określoną operację technologiczną na detalu (workpiece).

Stacje produkcyjne w zbiorze:

- **OV_1** – piec (oven) – realizuje aktywność **Burn** (wypalanie/podgrzewanie detalu)
- **MM_1** – frezarka (milling machine) – realizuje aktywność **Mill** (frezowanie)
- **SM_1** – sortownica (sorting machine) – realizuje aktywność **Sort** (sortowanie)
- **VGR_1** – robot chwytakowy (vacuum gripper robot) – realizuje aktywność **Pickup-move-oven** (pobranie i przeniesienie do pieca)
- **HBW_1** – magazyn wysokiego składowania (high-bay warehouse) – realizuje aktywność **Storage** (składowanie)
- **WT_1** – wózek transportowy (workpiece transport) – realizuje aktywność **Transport** (transport)

Rodzaje czujników i aktuatorów

Każde zdarzenie zawiera wektor sygnałów ze stacji. Sygnały dzielą się na:

- *Czujniki pozycji (i_pos_switch)** – przełączniki krańcowe, wartości binarne: **0** (nie wyzwolony) lub **1** (wyzwolony)
- *Bariery świetlne ($i_light_barrier$)** – czujniki obecności detalu, wartości binarne: **0** (brak detalu) lub **1** (detał wykryty)
- *Silniki (m_speed)** – prędkość silnika, wartości: **0** (stop), **512** (obróć w przód), **-512** (obróć wstecz)
- *Zawory (o_valve)** – sterowanie pneumatyczne, wartości: **0** (zamknięty) lub **512** (otwarty)
- *Sprężarki/kompresory ($o_compressor$)** – wartości: **0** (wyłączona) lub **512** (włączona)

Wartości **512** i **-512** (zamiast **1** i **-1**) wynikają z reprezentacji sygnałów PLC w skali 10-bitowej.

Struktura pojedynczego rekordu

Każdy rekord JSON w pliku **Signature_*.txt** ma postać:

```
{"station": "OV_1", "timestamp": "2023-03-20T10:11:01Z", "events":  
{"i1_pos_switch": 0, "i2_pos_switch": 0, ...}}
```

Polą:

- **station** – identyfikator stacji (zasób techniczny)
- **timestamp** – znacznik czasu ISO 8601 (UTC), próbkowanie co ~2 sekundy

- **events** – słownik sygnałów aktywnych w danej stacji

2. Kluczowe atrybuty logu zdarzeń

Atrybut	Dostępny	Źródło	Uwagi
case_id	Tak (odtworzony)	Nazwa pliku Signature_*	Brak jawnego case_id w rekordzie JSON
activity	Tak (odtworzona)	Nazwa pliku Signature_*	Brak jawnego pola activity w rekordzie
timestamp	Tak	Pole timestamp	Format ISO 8601, UTC, próbkowanie ~2s
resource	Tak (proxy)	Pole station	Brak zasobu ludzkiego; dostępna stacja/maszyna

Ograniczenia: Każdy plik sygnatury reprezentuje **jeden przypadek (case)** jednej aktywności. W rzeczywistym procesie produkcyjnym detal przechodzi przez wiele stacji – pełny log procesu wymagałby połączenia sygnatur z wielu stacji w jeden ślad przypadku.

3. Podstawowe statystyki zbioru

Statystyki globalne

Metryka	Wartość
Łączna liczba eventów	119
Liczba przypadków (cases)	6
Liczba aktywności	6
Liczba stacji	6
Łączna liczba kolumn sygnałów	26
Zakres czasowy	2023-03-20, 10:11 – 11:08 UTC

Liczba eventów i czas trwania per aktywność

Aktywność	Stacja	Liczba eventów	Czas trwania	Liczba sygnałów
Burn	OV_1	13	~25 s (10:11:01–10:11:26)	6
Mill	MM_1	12	~23 s (10:34:25–10:34:48)	8
Sort	SM_1	12	~23 s (10:12:06–10:12:29)	10
Pickup-move-oven	VGR_1	18	~34 s (11:08:02–11:08:36)	10
Storage	HBW_1	47	~93 s (10:30:28–10:32:01)	12

Aktywność	Stacja	Liczba eventów	Czas trwania	Liczba sygnałów
Transport	WT_1	17	~32 s (10:57:07–10:57:39)	6
SUMA		119		

Obserwacje:

- Aktywność **Storage** dominuje liczbą eventów (47 z 119, tj. **39,5%** wszystkich zdarzeń) i czasem trwania (93 s). Wynika to ze złożoności operacji magazynowania – robot HBW_1 wykonuje wiele ruchów w trzech osiach (m1, m2, m3, m4_speed).
- Aktywności **Burn**, **Mill** i **Sort** mają zbliżoną liczbę eventów (12–13) i czas trwania (~23–25 s).
- Pickup-move-oven** i **Transport** są pośrednie (17–18 eventów, ~32–34 s).
- Próbkowanie jest regularne – co ~2 sekundy, z nielicznymi wyjątkami (np. Burn: event 10–11 co 3 s).

Kolejność aktywności w czasie (timeline)

Wszystkie aktywności zarejestrowano tego samego dnia (2023-03-20). Kolejność chronologiczna:

```

10:11 Burn          (OV_1)
10:12 Sort          (SM_1)
10:30 Storage       (HBW_1)
10:34 Mill          (MM_1)
10:57 Transport     (WT_1)
11:08 Pickup-move-oven (VGR_1)

```

Aktywności **nie nakładają się** w czasie – każda sygnatura reprezentuje odrębny, sekwencyjny przypadek.

4. Analiza jakości danych

Wyniki kontroli jakości

Sprawdzenie	Wynik	Interpretacja
Duplikaty wierszy	0	Brak zduplikowanych rekordów
Duplikaty (case_id, timestamp, station)	0	Brak zduplikowanych zdarzeń
Błędy parsowania timestamp	0	Wszystkie 119 timestampów poprawnie sparsowane
Niemonotoniczność timestampów	0 przypadków	Czasy rosną monotonicznie w każdym case
Błędy typów sygnałów	0	Wszystkie wartości sygnałów są liczbowe
Kolumny z brakującymi wartościami	26 z 32	Patrz wyjaśnienie poniżej

Brakujące wartości – wyjaśnienie

W połączonej tabeli `df_full` (119 wierszy × 32 kolumny) większość kolumn sygnałów zawiera wartości **NaN**. Jest to **zachowanie oczekiwane i poprawne**, nie błąd danych.

Przyczyna: każda stacja używa tylko swoich czujników i aktuatorów. Np.:

- Stacja **OV_1** (Burn) raportuje tylko: `i1_pos_switch`, `i2_pos_switch`, `i5_light_barrier`, `m1_speed`, `o7_valve`, `o8_compressor` – pozostałe 20 kolumn to **NaN**
- Stacja **HBW_1** (Storage) raportuje: `i1-i4_light_barrier`, `i5-i8_pos_switch`, `m1-m4_speed` – 12 sygnałów

Tabela pokrycia sygnałów per aktywność:

Aktywność	Sygnały aktywne	Sygnały nieaktywne (NaN)
Burn	6	20
Mill	8	18
Sort	10	16
Pickup-move-oven	10	16
Storage	12	14
Transport	6	20

Wniosek: Brakujące wartości wynikają z architektury systemu (każda stacja ma własny zestaw czujników), a nie z błędów pomiarowych. Dane są kompletne w zakresie sygnałów właściwych dla każdej stacji.

Wartości sygnałów – analiza


Sygnały przyjmują wyłącznie wartości ze zbioru `{-512, 0, 512}` (dla silników i zaworów) lub `{0, 1}` (dla czujników binarnych). Brak wartości odstających ani anomalii numerycznych.

Przykładowe wartości dla aktywności **Burn** (OV_1):

- `m1_speed`: przyjmuje wartości `-512` (cofanie), `0` (stop), `512` (do przodu) – silnik napędu pieca
- `o7_valve`: `0` lub `512` – zawór pneumatyczny
- `i1_pos_switch`, `i2_pos_switch`: `0` lub `1` – przełączniki krańcowe pozycji

5. Eksploracyjna analiza danych (EDA)

Rozkład eventów per aktywność



Analiza sygnałów per aktywność

Burn (OV_1) – 13 eventów, 6 sygnałów

Sekwencja opisuje cykl pieca: otwarcie drzwi (`m1_speed = -512`), załadunek detalu, zamknięcie (`m1_speed = 512`), oczekiwanie, otwarcie i wyładunek. Zawór `o7_valve = 512` aktywny przez większość cyklu (podtrzymanie pozycji pneumatycznej).

Mill (MM_1) – 12 eventów, 9 sygnałów

Frezarka używa sprężarki (`o8_compressor = 512`) do chłodzenia/mocowania. Silniki `m1`, `m2`, `m3` sterują osiami XYZ. Czujniki `i1-i3_pos_switch` i `i4_light_barrier` monitorują pozycję i obecność detalu.

Sort (SM_1) – 12 eventów, 10 sygnałów

Sortownica używa taśmociągu (`m1_speed = -512` przez większość cyklu) i zaworów pneumatycznych (`o5_valve`, `o6_valve`) do kierowania detalu. Bariery świetlne `i1`, `i3`, `i6`, `i7`, `i8_light_barrier` śledzą pozycję detalu na taśmie.

Pickup-move-oven (VGR_1) – 18 eventów, 10 sygnałów

Robot chwytakowy wykonuje najbardziej złożony ruch: 3 silniki (`m1`, `m2`, `m3_speed`) sterują osiami, `o7_compressor` i `o8_valve` sterują chwytem próżniowym. Sekwencja obejmuje: opuszczenie, chwycenie detalu, podniesienie, obrót, przeniesienie do pieca.

Storage (HBW_1) – 47 eventów, 12 sygnałów

Magazyn wysokiego składowania jest najdłuższą aktywnością. Używa 4 silników (`m1-m4_speed`) do ruchu w 3 osiach + mechanizmu wyciągania. Czujniki `i1-i4_light_barrier` i `i5-i8_pos_switch` monitorują pozycję w regale. Duża liczba eventów wynika z konieczności precyzyjnego pozycjonowania w 3D.

Transport (WT_1) – 17 eventów, 6 sygnałów

Wózek transportowy używa jednego silnika (`m2_speed`) do jazdy i zaworów (`o5_valve`, `o6_valve`) do zatrzymania/blokady. Czujniki `i3_pos_switch`, `i4_pos_switch` wykrywają pozycje krańcowe.

Porównanie liczby sygnałów vs liczby eventów

Aktywności z większą liczbą sygnałów (Storage: 12, Sort/Pickup: 10) niekoniecznie mają więcej eventów – wyjątkiem jest Storage, gdzie złożoność mechaniczna (ruch 3D) generuje zarówno więcej sygnałów, jak i więcej kroków.

6. Analiza jakości pod kątem process mining

Dostępność atrybutów XES

Atrybut XES	Status	Uwagi
<code>case:concept:name</code>	Odtworzony	Z nazwy pliku: <code>case_Burn_001</code> , <code>case_Mill_001</code> , itd.

Atrybut XES	Status	Uwagi
<code>concept:name</code> (activity)	Odtworzona	Z nazwy pliku: Burn, Mill, Sort, itd.
<code>time:timestamp</code>	Dostępny	ISO 8601 UTC, monotoniczny, bez błędów
<code>org:resource</code>	Proxy	Pole <code>station</code> jako zasób techniczny

Ograniczenia dla process mining

1. **Jeden case per aktywność** – każdy plik sygnatury to jeden przypadek jednej aktywności. Brak wielokrotnych instancji tej samej aktywności.
2. **Brak case_id na poziomie rekordu** – `case_id` odtworzony z nazwy pliku, nie z danych.
3. **Brak zasobu ludzkiego** – tylko zasób techniczny (stacja).
4. **Sygnały niskopoziomowe** – dane to surowe sygnały PLC, nie zdarzenia procesowe wysokiego poziomu. Aplikacje CEP (Siddhi) służą do mapowania sygnałów na aktywności.
5. **Brak wariantów** – każda aktywność ma dokładnie jeden przypadek, więc analiza wariantów procesu nie jest możliwa na tym zbiorze.

7. Podsumowanie Milestone 1

Zbiór zawiera **119 eventów** z **6 aktywności** zarejestrowanych w laboratoryjnym środowisku produkcyjnym Fischertechnik w dniu 2023-03-20. Dane są wysokiej jakości: brak duplikatów, błędów timestampów i anomalii numerycznych. Brakujące wartości są strukturalne (każda stacja raportuje tylko swoje sygnały) i nie stanowią problemu jakościowego.

Kluczowe obserwacje:

- Aktywność **Storage** dominuje (47 eventów, 39,5%), co odzwierciedla złożoność operacji magazynowania 3D
- Próbkowanie regularne (~2 s), sygnały przyjmują wartości `{-512, 0, 512}` lub `{0, 1}`
- Dane gotowe do dalszej analizy: detekcji aktywności (CEP/Siddhi), konwersji do XES i process mining

Plik wykonawczy z kodem i wizualizacjami: `Milestone1_EDA.ipynb`.