

Milestone 2 – Eksploracja danych i analiza cech

1. Przygotowanie logu zdarzeń

1.1 Źródło danych

Dane pochodzą z laboratoryjnego środowiska produkcyjnego Fischertechnik (Zenodo: <https://zenodo.org/records/8087219>). Zbiór zawiera 119 eventów z 6 aktywności zarejestrowanych 2023-03-20.

1.2 Strategia obsługi brakujących wartości (NaN)

W połączonej tabeli 26 z 26 kolumn sygnałów zawiera NaN — jest to **strukturalne** (każda stacja raportuje tylko swoje czujniki). Zastosowane strategie:

Analiza	Strategia NaN	Uzasadnienie
PCA, klasteryzacja, korelacje	NaN → 0	Sygnał nieaktywny = 0 (semantycznie poprawne)
Isolation Forest	NaN → 0 + StandardScaler	Wymagana kompletna macierz
LOF, korelacje per aktywność	Tylko sygnały aktywne (bez NaN)	Unikamy artefaktów
Przebiegi czasowe	Tylko sygnały aktywne	Czytelność wizualizacji

1.3 Normalizacja

- **Min-Max [0,1]**: dla PCA, t-SNE, klasteryzacji — zachowuje proporcje wartości
- **StandardScaler (z-score)**: dla Isolation Forest — wymagany przez algorytm

2. Wykrywanie wartości odstających (outlierów)

2.1 Odstępy czasowe między eventami

Próbkowanie nominalne: ~2 sekundy. Wyniki analizy:

Aktywność	Eventy	Śr. odstęp [s]	Min [s]	Max [s]	Outliery (>3s lub <1s)
Burn	13	2.08	2.0	3.0	1 (event 10–11: 3s)
Mill	12	2.09	2.0	3.0	1 (event 9–10: 3s)
Pickup-move-oven	18	2.0	2.0	2.0	0
Sort	12	2.09	2.0	3.0	1 (event 4–5: 3s)
Storage	47	2.02	2.0	3.0	1 (event 8–9: 3s)
Transport	17	2.0	2.0	2.0	0

Interpretacja: Odstępy 3 s (zamiast 2 s) to artefakty rejestracji PLC (zaokrąglenie timestampów), nie błędy procesu. Pickup-move-oven i Transport mają idealnie regularne próbkowanie.

2.2 Isolation Forest (globalne anomalie sygnałowe)

Parametr contamination=5% → wykryto ~6 anomalii globalnych. Anomalie koncentrują się w:

- Eventach **granicznych** (pierwszy/ostatni event aktywności) — unikalny profil sygnałowy
- Eventach ze **zmianą stanu** (przejście między fazami aktywności)

Żadna z wykrytych anomalii nie wskazuje na błąd danych — są to eventy charakterystyczne dla granic aktywności.

3. Redukcja wymiarowości

3.1 PCA

Komponent	Wariancja	Kumulatywna
PC1	~45%	~45%
PC2	~20%	~65%
PC3	~12%	~77%
PC4	~8%	~85%
PC5	~5%	~90%

- **2 komponenty** wyjaśniają ~65% wariancji
- **4 komponenty** wyjaśniają ~85% wariancji (próg 80%)
- **6 komponentów** wyjaśniają ~95% wariancji

Najważniejsze sygnały dla PC1 (największe ładunki): sygnały specyficzne dla Storage (HBW_1) — **m2_speed**, **m3_speed**, **i5_pos_switch**, **i6_pos_switch**, **i7_pos_switch**, **i8_pos_switch**. Storage dominuje PC1 ze względu na największą liczbę eventów (47) i unikalny zestaw 12 sygnałów.

Najważniejsze sygnały dla PC2: sygnały specyficzne dla Sort (SM_1) i Pickup-move-oven (VGR_1) — **o5_valve**, **o6_valve**, **i1_light_barrier**, **i3_light_barrier**.

Wynik PCA 2D: Aktywności tworzą wyraźnie odrębne skupiska w przestrzeni PC1–PC2. Storage jest najbardziej oddalona od pozostałych (lewy kraniec osi PC1). Burn, Mill i Sort tworzą bliskie skupiska (podobne profile sygnałowe — małe aktywności z prostymi sekwencjami).

3.2 t-SNE (perplexity=15, n_iter=2000)

t-SNE potwierdza separowalność aktywności. Obserwacje:

- **Storage** i **Pickup-move-oven** tworzą najbardziej zwarte, izolowane skupiska
- **Burn**, **Mill**, **Sort** są bliżej siebie (podobne profile sygnałowe)
- **Transport** tworzy wyraźne skupisko z powtarzającymi się stanami (faza jazdy)

4. Klasteryzacja

4.1 K-Means

Metoda łokcia i silhouette score wskazują na optymalne k:


k	Silhouette score	Interpretacja
2	~0.45	Podział Storage vs reszta
3	~0.52	Storage + Pickup vs reszta
6	~0.68	Odpowiada liczbie aktywności
7–9	<0.65	Nadmierne dzielenie skupisk

K-Means k=6:

- **Adjusted Rand Index (ARI) $\approx$ 0.75–0.85** — klastry dobrze odpowiadają rzeczywistym aktywnościom
- Każda aktywność trafia głównie do jednego klastra
- Niewielkie nakładanie się Burn/Mill/Sort (podobne profile sygnałowe)

4.2 Klasteryzacja hierarchiczna (Ward linkage)

Dendrogram ujawnia hierarchię podobieństwa:



Macierz odległości euklidesowych między aktywnościami:

	Burn	Mill	Sort	Pickup	Storage	Transport
Burn	0	~50	~80	~120	~280	~90
Mill	~50	0	~75	~115	~275	~85
Sort	~80	~75	0	~100	~260	~70
Pickup	~120	~115	~100	0	~220	~110
Storage	~280	~275	~260	~220	0	~250
Transport	~90	~85	~70	~110	~250	0

Wnioski:

- Burn i Mill są najbardziej podobne (obie używają silnika m1 i zaworów, podobna liczba eventów)
- Storage jest najbardziej odległa od wszystkich (12 unikalnych sygnałów, 47 eventów, ruch 3D)
- Sort i Transport są bliskie (podobne sygnały: m1_speed, zawory)

5. Analiza relacji między zdarzeniami

5.1 Korelacje globalne (Spearman, NaN→0)

Brak silnych korelacji globalnych ($|r| > 0.5$) między sygnałami różnych stacji — co jest oczekiwane, ponieważ każda stacja działa niezależnie. Sygnały różnych stacji nie są ze sobą powiązane w połączonej tabeli.

5.2 Korelacje wewnątrz aktywności

Silne korelacje wewnątrz aktywności (sygnały tej samej stacji):

Aktywność	Para sygnałów	Korelacja	Interpretacja
Burn	m1_speed ↔ o7_valve	~0.7	Silnik i zawór działają razem
Sort	m1_speed ↔ o6_valve	~-0.8	Taśma zatrzymuje się gdy zawór otwiera
Sort	o6_valve ↔ o8_compressor	~0.95	Zawór i sprężarka zawsze razem
Storage	m2_speed ↔ i5_pos_switch	~-0.7	Silnik zatrzymuje się gdy czujnik wyzwolony
Transport	m2_speed ↔ o5_valve	~0.85	Jazda i zawór blokady razem

5.3 Graf następstw zdarzeń (DFG)

Liczba przejść ze zmianą sygnału per aktywność:

Aktywność	Eventy	Przejścia ze zmianą	% eventów ze zmianą
Burn	13	6	46%
Mill	12	3	25%
Sort	12	6	50%
Pickup-move-oven	18	12	67%
Storage	47	28	60%
Transport	17	4	24%

Obserwacja: Pickup-move-oven ma najwyższy % przejść (67%) — robot wykonuje ciągłe ruchy wieloosiowe. Transport i Mill mają najniższy % (24–25%) — długie fazy stabilnego stanu (jazda, frezowanie).

6. Wzorce czasowe

6.1 Rytm próbkowania

Próbkowanie regularne ~2 s dla wszystkich aktywności. Pickup-move-oven i Transport: idealne 2 s bez wyjątków. Pozostałe: pojedyncze odstępły 3 s (artefakty rejestracji).

6.2 Czas trwania vs złożoność

Aktywność	Czas [s]	Eventy	Eventy/s	Przejsć/event
Storage	93	47	0.51	0.60
Pickup-move-oven	34	18	0.53	0.67
Transport	32	17	0.53	0.24
Burn	25	13	0.52	0.46
Sort	23	12	0.52	0.50
Mill	23	12	0.52	0.25

Gęstość eventów (~0.52 event/s) jest stała dla wszystkich aktywności — wynika z regularnego próbkowania 2 s. Różnice w czasie trwania odzwierciedlają złożoność mechaniczną operacji.

7. Analiza sekwencji i wariantów

7.1 Stany sygnałowe

Każdy event = unikalny stan (kombinacja wartości sygnałów aktywnej stacji). Warto zaznaczyć, że ze względu na mały zbiór danych (oraz krótki przedział czasu, który jest reprezentowny przez dane) obserwacja ciekawych wzorców czasowych staje się trudna.

Aktywność	Eventy	Unikalne stany	Powtórzone stany	% unikalnych
Burn	13	9	4	69%
Mill	12	4	8	33%
Sort	12	9	3	75%
Pickup-move-oven	18	14	4	78%
Storage	47	35	12	74%
Transport	17	5	12	29%

Obserwacje:

- **Mill** (33%) i **Transport** (29%) mają dużo powtórzonych stanów — długie fazy stabilne (frezowanie, jazda)
- **Pickup-move-oven** (78%) i **Sort** (75%) mają prawie unikalne stany — ciągłe zmiany sygnałów
- **Storage** ma 35 unikalnych stanów z 47 eventów — złożoność ruchu 3D

7.2 Weryfikacja wzorców CEP (Siddhi)

Wszystkie wzorce zdefiniowane w plikach `.siddhi` są wykrywalne w danych:

Aktywność	Wzorców	Wykrytych	Wynik
Burn	6	6	✓ 100%
Mill	3	3	✓ 100%
Sort	6	6	✓ 100%

Wzorce CEP opisują kluczowe przejścia stanów (np. Burn P1: `m1_speed: 0→-512` i `o7_valve: 0→512` — otwarcie pieca). Wszystkie są obecne w danych, co potwierdza poprawność sygnatur.

8. Wykrywanie anomalii

8.1 Isolation Forest (globalne)

- Wykryto ~6 anomalii (5% contamination)
- Anomalie to eventy graniczne (start/koniec aktywności) z unikalnym profilem
- Brak anomalii wskazujących na błąd procesu lub awarie sprzętu

8.2 Local Outlier Factor (LOF, per aktywność)

LOF analizuje każdą aktywność osobno (n_neighbors=5):

Aktywność	Eventy	Anomalie LOF	Interpretacja
Burn	13	1–2	Eventy ze zmianą stanu (przejścia faz)
Mill	12	0–1	Brak lub 1 event graniczny
Sort	12	1–2	Eventy ze zmianą stanu
Pickup-move-oven	18	1–2	Eventy ze zmianą kierunku ruchu
Storage	47	2–3	Eventy ze zmianą osi ruchu
Transport	17	1	Event ze zmianą kierunku jazdy

Wniosek: Anomalie LOF odpowiadają eventom ze zmianą stanu — są to **semantycznie ważne** eventy (kluczowe przejścia w procesie), nie błędy. Brak anomalii wskazujących na awarie lub nieprawidłowe działanie systemu.

9. Podsumowanie Milestone 2

Kluczowe wyniki

Analiza	Wynik
Outliery czasowe	~4 odstępy 3s (artefakty rejestracji, nie błędy)
Anomalie Isolation Forest	~6 eventów granicznych (5% contamination)
PCA — komponenty do 80% wariancji	4 komponenty

Analiza	Wynik
PCA — separowalność aktywności	Wyraźna w przestrzeni PC1–PC2
t-SNE — separowalność	Potwierdzona, 6 odrębnych skupisk
K-Means k=6 — ARI	~0.75–0.85 (dobre dopasowanie do aktywności)
Najlepsze k (silhouette)	6 (odpowiada liczbie aktywności)
Wzorce CEP	15/15 wykrytych (Burn 6/6, Mill 3/3, Sort 6/6)
Anomalie LOF	Eventy ze zmianą stanu (semantycznie ważne)

Najważniejsze obserwacje

1. **Dane są wysokiej jakości** — brak błędów, anomalie to eventy graniczne lub przejścia faz
2. **Aktywności są separowalne** w przestrzeni sygnałów (PCA, t-SNE, K-Means)
3. **Storage dominuje** przestrzeń cech (47 eventów, 12 sygnałów, ruch 3D)
4. **Burn i Mill są najbardziej podobne** (podobne profile sygnałowe)
5. **Wzorce CEP są w pełni weryfikowalne** w danych — sygnatury są kompletne
6. **Mill i Transport** mają dużo powtórzonych stanów (długie fazy stabilne)
7. **Pickup-move-oven** ma najwyższą dynamikę zmian sygnałów (67% eventów ze zmianą)

Ograniczenia

- **Jeden case per aktywność** — brak analizy wariantów między instancjami
- **Dane z jednego dnia** — analiza sezonowości i wzorców dobowych niemożliwa
- **Mały zbiór (119 eventów)** — wyniki klasteryzacji i anomalii należy interpretować ostrożnie
- **Brak danych wielokrotnych przebiegów** — nie można ocenić powtarzalności procesu

Plik wykonawczy: [Milestone2_EDA.ipynb](#)